

Prompt 1d — Filtro de pertinencia, huecos sin explicar y gobernanza del panel

La primera noche salió muy bien: 172/172, 95,9% de cobertura, 0 bloqueos, 16,1 s de CPU y 65 MB de RSS. Esto son tres cosas puntuales sobre lo que muestra ese resultado.

```
Repo: github.com/leanchoi/leanchoi, rama claude/esquel-data-ecosystem-integration-qbxuv2.  
`git pull --rebase`: hay cambios en specs/sql/01_air_schema.sql y docs/01-motor-aereos.md.
```

```
=====
```

P0 – Itinerarios internacionales contaminando la serie de cabotaje

```
=====
```

El desglose de la primera noche trae, sobre rutas de cabotaje patagónico:

LATAM (LA): 13 itinerarios
GOL (G3): 4 itinerarios

Ninguna de las dos opera cabotaje argentino. GOL solo conecta aeropuertos argentinos con sus hubs en Brasil (GRU-BRC estacional de invierno, GRU-USH). LATAM cerró su filial doméstica en 2020 y vuela a Bariloche desde hubs internacionales; fue autorizada a cabotaje hace poco pero no lo lanzó.

0 sea: son BUE->BRC vía São Paulo o vía Santiago. Desvíos internacionales que Google ofrece como alternativa y que NO son el mercado que medimos.

17 sobre 900 parece poco. No lo es:

- Contaminan la mediana de la celda.
- Pueden ganar el `is_cheapest_of_query` y quedar como "el precio del mercado".
- ROMPEN LA NORMALIZACIÓN POR KILÓMETRO, que divide por la distancia geodésica directa mientras el itinerario real pasó por Brasil. El indicador de paridad —el más importante para la discusión pública— quedaría sobre un absurdo.

Implementé un filtro de pertinencia con estos criterios:

- Todas las escalas dentro de Argentina.
- Operador con derechos de cabotaje vigentes (lista en config, versionada).
- Duración $\leq 2,5 \times$ la del directo de referencia de esa ruta.
- Escalas ≤ 1 , salvo rutas sin directo (COR-EQS fuera de temporada): ≤ 2 .

REGISTRALOS IGUAL, no los descartes: `itinerario_relevante = false` más `motivo_irrelevancia (escala_internacional | duracion_excesiva | escalas_excesivas | operador_sin_cabotaje)`. La capa bronce guarda hechos, así el filtro se puede revisar y re-aplicar sin volver a scrapear.

Y de yapa queda una serie útil: cuántas veces Google ofreció un desvío internacional en una ruta doméstica es, en sí, un indicador de escasez de oferta.

Recalculé el desglose de la primera noche con el filtro aplicado y reporté cuánto se movieron la mediana y el mínimo de BUE->BRC. Ese delta es la medida de cuánto habría contaminado la serie.

=====

P1 – Los 7 sin_resultados quedaron sin explicar

=====

Los reportaste como "fechas puente / ventanas específicas sin disponibilidad". sin_resultados es, por definición, el estado que significa "no sé por qué": es el único que no puede quedar descrito en general.

Enumeré los 7: ruta, fecha, día de semana, lead, respuesta_valida, tamaño del blob. Y clasificalos. Sospecho que hay al menos dos causas distintas:

- Fechas muy lejanas donde la aerolínea todavía no cargó itinerarios. Si es eso, merece un estado propio (fuera_de_ventana_de_venta): no es un hueco de captura ni una falta de servicio, y no debería descontar cobertura.
- Vuelos genuinamente agotados. Eso SÍ es un dato valioso –capacidad agotada es la señal S3 del monitor– y hoy se está registrando como si fuera un fallo.

Cualquiera de las dos que aparezca, necesita su propio estado. El objetivo es que sin_resultados tienda a cero: mientras tenga volumen, significa que hay algo que el sistema no entiende de sí mismo.

=====

P1 – Gobernanza del panel de consulta (puerto 38530)

=====

El panel está bien hecho y Leandro lo pidió, así que se queda. Dos cosas:

- a) NO TIENE AUTENTICACIÓN y está en un puerto abierto a internet. Esquel Data tiene cookie de sesión y roles (permisos.py), y docs/06 §9 define qué ve cada rol. Acá quedan expuestos públicamente indicadores de grado C sobre una sola celda, que por la invariante I15 no son afirmaciones publicables. Poné al menos basic auth o allowlist de IP. No es que el dato sea secreto: es que un observatorio público no debería tener dos puertas con reglas distintas.
- b) ALCANCE, para que no se convierta en el Frankenstein que el proyecto entero quiere evitar. Dividí el panel explícitamente en dos:
 - CONSOLA DE OPERACIÓN (bitácora, canario, disco, calendario de servicio): esto es tuyo, es permanente y está bien que viva separado. Nadie más lo va a construir y es exactamente lo que hace falta para operar el colector.
 - VISTAS ANALÍTICAS (comparativa patagónica, explorador de vuelos): son un preview. Las va a construir F4 dentro de Esquel Data, con el catálogo

semántico y el cross-filtering de DuckDB-WASM. Ponéles un banner visible que diga "vista provisional – la versión definitiva vive en Esquel Data", y que lean las etiquetas y unidades desde generated/web/indicadores.ts para que las definiciones no puedan divergir. Se retiran cuando F4 aterrice.

=====

P2 – Verificar el footprint de disco después del arreglo

=====

Dos números no cierran entre sí:

- Antes reportaste el crudo en 2.085.158 bytes comprimido; ahora decís que el HTML completo pesa ~300 KB. Son un factor de 7 de diferencia.
- El panel muestra 47,9 MB ocupados. Sobre 172 consultas son 278 KB por consulta, sospechosamente parecido a "~300 KB de HTML por consulta". Si el blob JSON pesa 3-8 KB, el ocupado debería ser ~1 MB más las 5 fixtures.

Puede ser simplemente que los 47,9 MB incluyan la corrida previa al arreglo. Pero confirmalo: medí el footprint incremental de UNA noche posterior al cambio y reporté bytes/consulta reales.

=====

CRITERIOS DE ACEPTACIÓN

=====

1. Ningún itinerario de LA ni G3 entra en los agregados de rutas domésticas, y quedan registrados con `itinerario_relevante=false` y su motivo.
2. Reportado cuánto se movieron mediana y mínimo de BUE->BRC al aplicar el filtro.
3. Los 7 `sin_resultados` enumerados y clasificados; los estados nuevos que hagan falta, implementados.
4. El panel pide credencial o restringe por IP.
5. Las vistas analíticas del panel llevan banner de provisionalidad y toman etiquetas del catálogo generado.
6. Footprint real de disco por consulta, medido después del arreglo.

Y lo que sigue pendiente de Fla: noches 2 y 3. Reporté el desglose por estado de cada una.